

行业背景

近年来，人工智能正在重塑跨境电商的市场洞察方式。亚马逊在2026年发布的跨境电商白皮书中披露，中国卖家的AI使用率已超过98%。越来越多卖家开始用自然语言处理技术自动梳理海量评论，把过去依赖人工逐条翻阅的工作交给算法完成。对耳机这类体验型产品而言，音质、降噪、佩戴等细颗粒度反馈散落在大量英文长评论中，谁能更快更准地定位问题，谁就能在产品迭代与差评挽回上抢先一步。

SoundInsight蓝牙耳机音质差评智能归因系统

方案概述

这是我第一次参加这类比赛，也是第一次试着解决一个真实的商业命题。面对这个题目，我没有先想宏观的数据模型，而是先问自己：我最熟悉什么品类？答案是头戴式耳机，我几乎每天戴着它，对音质好坏有自己的判断，于是我试着从卖家的视角看问题。翻过真实评论我发现，卖家不是缺数据，而是数据太多太乱，音质问题藏在长评论里，只能靠人工逐条翻看，很难快速定位。这个系统要做的，就是把它交给机器，帮卖家看清音质差评的分布与原因。

目标用户是跨境电商平台上的耳机类目卖家，尤其是团队规模小、缺少专业数据分析人员的中小卖家。核心痛点是差评数量大、语言杂，人工翻看耗时耗力，音质类问题藏在长文本里难以归类和统计，产品改进与客服应对总是滞后。

复赛核心提升

初赛阶段（63条正例）：F1=0.37，最优阈值0.0009，模型对音质差评几乎无判别信心。复赛阶段（1257条高质量正例）：5折交叉验证平均F1=0.62±0.02，最终模型验证集F1=**0.687**，最优阈值**0.97**，模型对音质差评具备强判别能力。提升幅度：**+85.7%**|超越SVM基线：**+38.2%**

核心功能包括：音质差评自动识别，输入评论即可判断是否为音质负面并给出概率；五类问题归因，自动把差评归入低音、清晰度、杂音、音量、高音五类问题；一键洞察报告，输入评论文件一条命令生成差评率、问题分布与整改建议；批量分析，对整批评论批量打分并输出统计；结果可解释，给出判定概率与问题类别，让卖家明白模型为什么这么判断。

方案亮点在于用十万条真实评论构建了两阶段标注流水线，规则初筛配合大模型全量复核，把弱标注精度从五成提升到可训练水平，再用轻量模型蒸馏大模型的判断能力，同时完成五类音

质问题的细粒度归因。预期效果是卖家几分钟即可完成过去数小时的差评梳理，音质问题定位从凭经验翻看变为数据驱动，为选品、质检和客服话术提供直接依据。

技术方案

二分类模型采用DistilBERT-base微调。训练集按1:10欠采样（约1000正例+10000负例），学习率 $2e-5$ ，batchsize16，epochs3。验证集固定为20000条分层抽样样本（251正例），通过阈值扫描确定最优决策阈值0.97。

两阶段标注（RLCA）规则初筛召回高置信度音质差评，LLM全量复核音质相关三星评论补全委婉表达漏检。弱标注精度51.8%，清洗后标注精度约78%，正例从63条扩充至1257条。

多标签归因采用独立分类头架构，对低音、清晰度、杂音、音量、高音五类音质问题分别预测。宏F10.65，其中杂音0.84、音量0.84、低音0.79、清晰度0.77。

系统架构数据层→标注层（RLCA）→模型层（DistilBERT二分类+多标签）→应用层（Agent一键报告+GradioDemo）。

数据处理方式数据来源于McAuleyLab官方发布的AmazonElectronics真实评论数据集，共十万条。规则初筛采用单词边界匹配，关键词表涵盖低音、清晰度、发闷、失真、电流声等二十余个音质特征词，命中且评分低于等于两星视为正例候选。

AI Agent或工作流用户输入一段或一批英文评论后，系统先做文本预处理，统一格式并截断到固定长度；随后把文字转换为数字表示；二分类模型输出音质负面概率，超过阈值即判定为音质负面；多标签模型进一步把差评归入五类音质问题；系统汇总差评率、问题分布与典型案例，自动生成洞察报告，支持单条即时体验与批量统计导出。

前后端及其他技术组件前端使用Gradio框架搭建网页界面，提供单条判定与批量分析两个页面；后端采用Python，基于PyTorch与Transformers库完成模型推理；一键Agent以命令行形式封装，输入评论文件即可产出报告；模型文件打包成单一目录，可部署到普通云服务器或本地电脑直接运行。

方法说明小模型与LLM教师答案的一致率为83.7%加减2.1%，仅用于说明知识蒸馏可行性，不作为模型性能证据。

附加材料说明

系统架构流程图：已生成文本版流程图，从用户输入到结果展示共八个节点。Demo推理结果图：三条测试评论的预测概率柱状图，含阈值参考线，证明模型能有效区分音质负面与正常评论。训练结果验证：五折交叉验证（分层划分，每折验证集约251条正例）调优阈值F1均值0.6234加减0.0240，波动3.9%，准确率约百分之九十九；最终模型在独立验证集两万条评论上F1为0.624，调优阈值0.97后F1为0.687，召回率约九成；初赛在五千条数据与六十三条正例上F1仅0.37，复赛通过十万条数据与两阶段标注将F1提升至0.62。核心实验数据汇总如下表。受限于数据规模，模型对委婉表达与多语言场景的识别仍有不足。

核心实验结果

指标	数值	说明
清洗标签5折CV平均F1	0.6234±0.0240	逐折: 0.6655/0.6151/0.6325/0.6054/0.5983，波动3.9%
最终模型验证集F1	0.687（阈值0.97）	较初赛F10.37提升85.7%
SVM基线F1	0.497±0.017	传统方法天花板
逻辑回归基线F1	0.410±0.022	—
多标签归因宏F1	0.65	低音0.79/清晰度0.77/杂音0.84/音量0.84

数据与代码：全部代码已整理至GitHub仓库，地址为<https://github.com/DaiYanQBZ95Doll/soundinsight>，包含数据获取、两阶段标注、训练、交叉验证、推理、Agent和Demo全流程脚本。

图1：三条测试评论预测概率柱状图

三条测试评论的音质负面概率预测柱状图，含阈值参考线

(预留空白页，请在此插入图片文件：C:\deepseek-harness-master\soundinsight\demo_output.png)

图2：验证集混淆矩阵

验证集混淆矩阵，展示模型对音质负面与正常评论的判定分布

(预留空白页，请在此插入图片文件：C:\deepseek-harness-master\soundinsight\confusion_matrix.png)

附录：训练结果完整控制台输出

```
来源文件: C:\deepseek-harness-master\soundinsight\training_output.txt
csv: C:\deepseek-harness-master\soundinsight\labeled_llm.csv | label: sound_negative_llm
val n=20000 pos=251

threshold sweep on validation set:
  thr      acc      prec      rec      f1 pred_pos
0.500 0.9865 0.4787 0.8964 0.6241      470
0.200 0.9837 0.4291 0.9044 0.5821      529
0.100 0.9813 0.3948 0.9124 0.5511      580
0.050 0.9800 0.3789 0.9283 0.5381      615
0.010 0.9727 0.3102 0.9602 0.4689      777
0.001 0.9158 0.1289 0.9920 0.2282     1931

Confusion matrix at tuned threshold:
[[19658    91]
 [   72   179]]
TN=19658 FP=91 FN=72 TP=179
saved C:\deepseek-harness-master\soundinsight\confusion_matrix.png (threshold=0.9744497537612915)

Sample predictions on real reviews:
[99.0%] The sound quality is terrible, the bass is muddy and there is constant
[0.0%] Great battery life and very comfortable fit.
[98.8%] Sounds crackle and hiss constantly, completely unusable.
```