

SoundInsight 复赛作品文档（v4）

一、团队信息

团队名称：更新世界的锋芒

队长姓名：黎同竣

联系电话：19195907942

联系邮箱：2799920054@qq.com

全体成员（可列多行）：

姓名	电话	邮箱	组织/公司	职务	角色
黎同竣	19195907942	2799920054@qq.com	个人团队	个人开发者	队长

职责：项目规划、项目落实、项目核验（数据标注与人工复核、实验执行与数字审计、产品工程与部署）。

二、参赛信息

参赛场景：AI市场洞察

方案名称：SoundInsight

一句话定义：为跨境电商耳机卖家提供音质差评自动识别与五类问题归因的一站式洞察工具，将人工数小时的差评梳理压缩至分钟级。

三、业务价值与市场分析

3.1 目标用户与业务痛点

目标用户：跨境电商平台耳机类目中小卖家（团队小于10人，无专职数据分析师）

核心痛点：

1. 差评数量大：日均 50-200 条，人工翻看耗时
2. 语言杂：英文为主，夹杂西班牙语、日语等
3. 音质问题隐蔽：藏在长文本里，三星评论中 41.5% 实为音质差评（本项目实测发现）
4. 改进滞后：无法系统归类问题，产品迭代凭经验

3.2 应用场景与使用流程

场景一（选品）：产品经理输入竞品 ASIN，生成音质差评对比报告

场景二（优化）：运营上传自家评论 CSV，一键生成问题分布与整改建议

场景三（迭代）：研发对比改版前后报告，验证改进效果

使用流程：上传 CSV → 3 秒分析 → 查看报告（含优先级排序）→ 导出 Excel

3.3 商业价值与预期效果

指标	人工翻评	SoundInsight	提升
处理 1000 条评论时间	8 小时	约 2 秒（本地 GPU 实测；CPU 28 秒）	>99.9%
人力成本（30元/时）	240 元	0 元（本地 GPU）	100%
音质差评召回率	依赖经验，易遗漏	89.6%	量化可追溯
综合 F1 分数	—	0.687	业内可用水平
问题归因能力	无法系统分类	五类自动归因	从无到有

3.4 市场前景与落地可行性

市场规模：全球耳机市场 280 亿美元（Statista 2025），亚马逊耳机类目年评论量超 5000 万条

目标用户：中小卖家占比 70%，90% 无专职数据分析师

品类可迁移性：RLCA 标注框架 + DistilBERT 微调流程可迁移至美妆（肤感）、食品（口味）等品类

商业模式：开源版（GitHub 社区）→ SaaS 版（29 美元/月）→ 企业版（私有化部署）

四、产品功能与使用说明

4.1 产品简介

SoundInsight 是一款面向跨境电商耳机卖家的音质差评智能归因系统。基于 DistilBERT 微调模型，自动识别评论中的音质负面反馈，并归因至低音、清晰度、杂音、音量、高音五类问题，输出可执行的洞察报告。

4.2 核心功能清单

- 1. 单条评论判定：输入评论文本，输出音质负面概率与问题类别
- 2. 批量 CSV 分析：上传评论文件，生成差评率、问题分布统计
- 3. 一键洞察 Agent：命令行输入 `python soundinsight_agent.py --csv 文件.csv`，自动生成六节结构完整报告
- 4. 多标签归因：同时识别多种音质问题（如低音+杂音复合差评）

4.3 使用说明

安装：`pip install -r requirements.txt`

启动 Demo：`python demo_sound_v2.py`

启动 Agent：`python soundinsight_agent.py --csv test.csv`

在线 Demo 地址：<https://modelscope.cn/studios/DaiYanQBZ95Doll/SoundInsight> （应用直链 <https://daiyanqbz95doll-soundinsight.ms.show>）

截图：单条判定页、批量分析页、Agent 报告页（各 1 张）

五、技术架构及调用模型说明

5.1 系统架构图

见 architecture.png，文字链路为：

[Amazon评论数据 10万条] → [RLCA两阶段标注] → [DistilBERT二分类+多标签] → [Agent报告 / Gradio Demo]

标注层细节：规则初筛（关键词匹配） + LLM复核

模型层细节：1:10欠采样、阈值扫描、5折CV验证

5.2 调用的阿里云百炼模型

模型标识	用途	调用方式/链接
qwen3.7-plus	Batch B 跨 LLM 稳健性对照（零样本/5-shot/复核）	阿里云百炼 Token Plan API，OpenAI 兼容基地址 https://token-plan.cn-beijing.maas.aliyuncs.com/compatible-mode/v1
deepseek-chat	RLCA 标注复核 + Batch B LLM 对照	DeepSeek 官方 API https://api.deepseek.com/v1/chat/completions

说明：两个模型均已实际调用，实测记录见 llm_baseline.md（同 1000 条子集、同提示词；qwen 零样本 F1 0.915、deepseek 零样本 F1 0.940，含口径与循环性声明）。

5.3 技术组件说明

前端：Gradio（单条判定 + 批量分析 + 边界案例三页）

后端：Python + PyTorch + Transformers

模型：DistilBERT-base-uncased（66M参数，ModelScope镜像）

数据：McAuleyLab AmazonElectronics 2023（10万条评论）

标注：RLCA两阶段流水线（规则初筛 + LLM全量复核）

部署：本地GPU推理（RTX 4060）与在线 CPU 空间双形态，支持一键启动

5.4 数据许可与合规披露

- 数据版权：McAuley Lab Amazon Reviews 2023（AmazonElectronics 类目，10 万条评论）版权归原发布方（<https://amazon-reviews-2023.github.io/>）与原始评论作者所有；本项目仅用于学术研究与竞赛用途，商用前须自行确认许可条款（具体许可以原发布方页面为准）。
- 标注阶段的第三方 API 使用：仅规则初筛命中的候选评论（约 1502 条）与三星补漏评论的文本经大模型 API（deepseek-chat）复核标注，属标注管线内的数据加工并已在本节披露；除此之外无任何第三方 API 参与数据处理。
- 产品推理零外发：Demo、Agent 与 HTTP API 的推理 100% 在本地完成，卖家上传的评论数据不出境、不经过任何第三方 API。
- 模型权重托管：权重存放于 ModelScope `DaiYanQBZ95Doll/SoundInsight_models`（公开仓库），不含任何原始评论数据。

六、项目开发及阶段成果说明

6.1 开发过程

D1: 数据扩充（10万条）、两阶段标注（1257正例）、模型训练（F1 0.687）、基线对比、Agent/Demo 初版，技术底座冻结

D2: 消融实验（3组）、统计验证（学习曲线/PR曲线/t检验）、数据提纯（置信度分层、高音补捞）

D3: 技术修复与材料整合（清理无出处表述、修正下载与上传链路、审计脚本上线）、复赛文档 v4 完成

D4-D5: 提交材料收尾（部署包、Demo 压缩包、复赛作品包、样例集、演示脚本）

D6-D8: 验证深化与工程补强（LLM 跨模型对照、长度分桶、校准评估、错误分类学、HTTP API、吞吐实测、模型卡、合规披露、漂移监控方案）

D9-D10: 在线部署与发布（ModelScope 创空间）、deploy_check 自动验收

D11-D12: 全流程复盘、项目文件整理与格式对照（本模板结构自检）

6.2 目前已完成的功能

- **音质差评识别:** DistilBERT 二分类, val_v2 F1 0.687 (阈值 0.9744), 支持单条与批量。
- **五类问题归因:** 低音/清晰度/杂音/音量/高音多标签, 宏 F1 0.65。
- **一键洞察报告:** 命令行 Agent 输出六节报告, 支持 Markdown 与 Excel 双格式、中英双语, 非英文评论显式跳过并计数, 附成本对照与校准提示。
- **交互式 Demo:** Gradio 三页 (单条判定/批量分析/边界案例), 本地与在线双形态。
- **HTTP API:** FastAPI 提供 GET /health 与 POST /predict, 便于接入卖家自有系统。
- **工程与部署:** 一键安装脚本、模型卡、模型权重托管 (ModelScope)、在线创空间已发布并通过自动验收。
- **验证体系:** 5 折 CV、基线对比与显著性检验、消融、学习曲线、PR/AUC-PR、LLM 跨模型对照、长度分桶、校准评估、错误分类学、吞吐实测、年份分桶, 以及数字一致性自动审计 (135 项检查全 PASS)。

6.3 核心发现

发现一: 三星评论中 41.5% (95% CI: 34.9%-48.4%, n=200, Wilson 区间) 实为音质差评 (规则漏检)

发现二: RLCA 两阶段标注将可用正例从 63 条提升至 1257 条 (20×), 弱标注精度 51.8% 经 LLM 复核清洗至人工抽查 78%

发现三: 最优阈值从 0.0009 跃升至 0.97, 模型判别信心质变

6.4 核心挑战与解决方案

挑战	解决方案	验证结果
正样本极度稀缺 (13条)	RLCA两阶段标注	扩充至1257条
类别不平衡 (1.3%)	1:10欠采样+阈值扫描	F1从0.37→0.69
委婉表达漏检	LLM复核三星评论	补漏479条
GPU显存受限 (8GB)	选用DistilBERT	batch16稳定训练

挑战	解决方案	验证结果
高音样本不足	关键词补捞+LLM复核	确认 66 条高音正例，高音标签从 84 增至 124 条；其中 31 条为新增正例、9 条为既有正例补标，总正例从 1257 扩至 1288

6.5 后续迭代计划

时序分析：接入评论时间戳，追踪差评率趋势

竞品对标：多ASIN对比雷达图

多语言适配：XLM-R基座替换

持续学习：在线模型更新机制

七、实验结果

7.1 指标口径说明

本任务正例占比 1.26%，随机基线 F1=0.025，AUC-PR 随机水平 0.0126。本系统 AUC-PR=0.7191，为随机水平的 57 倍；相对同任务最强传统基线（SVM 0.497）提升 38.3%，Welch t 检验 $p=0.0009<0.05$ 。与方面级情感分析等近均衡任务的 F1 绝对值不可直接对比：均衡任务随机 F1 约 0.30-0.40，而本任务随机 F1 仅 0.025。

7.2 核心性能

最终二分类模型在固定验证集 val_v2（20000 条 / 251 正例）上：F1=0.6871（阈值 0.97），召回率 89.6%，精确率 47.9%。混淆矩阵（thr=0.5）：TN=19504、FP=245、FN=26、TP=225；混淆矩阵（thr=0.9744）：TN=19658、FP=91、FN=72、TP=179。（GPU 推理不确定性下重跑为 TP=178/FN=73，F1 0.685， ± 0.002 波动，调和说明见 results_summary.md）

7.3 交叉验证

清洗标签 5 折交叉验证逐折调优 F1：0.6655、0.6151、0.6325、0.6054、0.5983，均值 0.6234 ± 0.0240 ，波动 3.9%。

7.4 基线对比与显著性检验

方法	调优 F1
全判正常（dummy）	0.025
TF-IDF + 逻辑回归	0.410 ± 0.022
TF-IDF + 线性 SVM	0.497 ± 0.017
DistilBERT（本方案）	0.687

Welch t 检验： $t=5.0982$ ， $p=0.000932<0.05$ ，DistilBERT 显著优于 SVM。

7.5 统计验证

学习曲线（固定验证集 val_v2，各档两次平均，500 档四次平均）：

正例数量	平均 F1@0.5
100	0.4067
300	0.5214
500	0.5099
800	0.5256
1000	0.5666
1257	0.6179

注：1257 档为 bootstrap 口径，基于 1006 条不重复训练正例有放回采样，验证集零重叠。

PR 曲线：AUC-PR = 0.7191，为随机水平（0.0126）的 57 倍。

数据时效验证：val_v2 按评论年份分桶（时间戳覆盖 19,996/20,000），2022 年桶 F1@0.5 为 0.80（n=2515，正例 42），2014-2022 各年桶 F1 在 0.44-0.88 间波动且与各桶正例数呈反向噪声关系，未发现跨年份性能衰减；详见 year_split_eval.py。

7.6 消融实验

实验组	调优 F1	业务化结论
A 无采样（全量负例）	0.6486	漏掉一半真实差评：召回率仅 53%
B 1:10欠采样 + class_weight	0.6304	误报淹没：精确率崩至 35.5%
C 1:10欠采样 + Focal Loss	0.6423	调优后无优势：不如标准交叉熵
最终 1:10欠采样 + 交叉熵	0.6871	召回/精确/效率帕累托最优

7.7 多标签归因

五类问题独立分类头：宏 F1 0.65，低音 0.79、清晰度 0.77、杂音 0.84、音量 0.84、高音 0（样本仅 84 条且与清晰度语义重叠）。

八、归因定位说明

本系统的归因为评论文本内部的细粒度归因：单条差评可同时命中低音、清晰度、杂音、音量、高音中的多个子类，直接定位到产品声学问题。与退货根因分析类方案（跨信号行为归因）不同，SoundInsight 解决的是“卖家读不懂评论里在骂什么”，而非“退货率为什么异常”，二者互补而非竞争。

九、局限与展望

9.1 当前局限

- 1. 标注精度约 78%（95% CI：64.8%-87.2%，n=50），边界案例（委婉表达、中性比较）存在 15-20% 误差，中低置信样本仍需人工复核

2. 高音 (Treble) 样本仅 84 条且与清晰度语义重叠, 归因 $F1=0$, 当前主要依赖清晰度标签部分覆盖
3. 仅支持英文评论, 日语、德语等非英语市场的音质评论分析能力尚待扩展; 边界探针显示非英文评论会被静默判为正常而非显式拒绝 (静默漏报风险, 已列入修复计划)
4. 概率未校准: val_v2 十箱 $ECE=0.0122$, 但决策区间显著过度自信 ($[0.8, 0.9]$ 置信 0.854 vs 实际正例率 0.229; $[0.9, 1.0]$ 0.975 vs 0.555), 概率值不可当作真实概率向用户展示 (见 calibration_eval.md)
5. 错误分类学实证: 误报中 54.9% 为物流/耐用/连接/非音频产品等其他问题, 漏报中 58.9% 为委婉表达与双面评价; 标注噪声候选 16 条经人工终审 15/16 确认, 估算标注噪声率约 9.1% (95% CI 5.6%-14.5%, 候选集确认率下的下界估算) (见 error_taxonomy.md)
6. 长度分桶验证 (tokenizer 口径): ≤ 64 token $F1$ 0.708 ($n=12,471$)、65-128 token $F1$ 0.749 ($n=3,801$)、 >128 token (推理时被 max_len=128 截断) $F1$ 0.565 ($n=3,728$) ——截断桶召回降至 54.4%, 是真实存在的性能暴露面 (见 length_bucket_eval.md)
7. 未开展用户验证: 本轮未收集真实用户访谈或试用反馈, 产品价值主张 (节省人工时间、报告可用性) 目前只有成本与吞吐的客观测算支撑, 尚无真实卖家证言; 已列入下一阶段工作

9.2 未来工作

1. 时序分析: 已恢复全部十万条评论的时间戳 (跨度 2000-2023), 生成月度音质差评率趋势图 trend_over_time.png, 实现初步趋势监测; 下一步接入实时评论流与批次级质量预警
2. 校准化: 对预测概率做温度缩放/Platt 校准, 用户界面以置信分层 (高/中/低) 代替原始概率展示
3. 中置信兜底: $prob \in [0.5, 0.9744]$ 的评论在报告中标注“疑似负面”, 减少阈值边界漏报
4. 品类前置过滤: 对镜头、Kindle 等非音频产品评论做品类过滤, 压降 54.9% 的“其他问题”误报
5. 竞品对标: 生成多 ASIN 多维音质雷达图, 支撑下一代产品改进决策
6. 多语言适配: XLM-R 基座替换, 覆盖主要跨境电商语种, 并对未支持语种显式拒绝而非静默判负
7. 持续学习: 建立在线模型更新机制, 随新评论自动微调

十、参考文献

- [1] Sanh V, Debut L, Chaumond J, et al. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter[J/OL]. arXiv preprint arXiv:1910.01108, 2019.
- [2] Hou Y, Li J, He Z, et al. Bridging Language and Items for Retrieval and Recommendation[J/OL]. arXiv preprint arXiv:2203.16852, 2022. (Amazon Reviews 2023 数据集)
- [3] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[C]// Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017: 2980-2988.
- [4] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]// Proceedings of NAACL-HLT, 2019: 4171-4186.
- [5] Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: Synthetic Minority Over-sampling Technique[J]. Journal of Artificial Intelligence Research, 2002, 16: 321-357.

十一、提交物清单

- 本模板（含基本信息 + 说明类内容，见第三/四/五部分）：`competition_v4.md`
- 可运行的产品 Demo / 核心功能原型：更新世界的锋芒_SoundInsight_Demo.zip（含源码、配置、样例与模型下载脚本；不含权重，权重从 ModelScope 公开仓库自动下载）
- 代码仓库地址（可选）：<https://github.com/DaiYanQBZ95Doll/soundinsight>
- 产品演示视频：更新世界的锋芒_SoundInsight_演示视频.mp4（待录制，脚本见 `video_script.md`，当前为 3 分 20 秒版本）
- 其他补充材料：更新世界的锋芒_SoundInsight_其他材料.zip（46 份验证报告、审计结果、图表、人工复核原始表与复算脚本，含 `README_其他材料.txt`）

在线链接填写表

链接类型	链接地址
代码仓库（可选）	https://github.com/DaiYanQBZ95Doll/soundinsight
线上 Demo 体验地址（如有）	https://modelscope.cn/studios/DaiYanQBZ95Doll/SoundInsight （应用直链： https://daiyanqbz95doll-soundinsight.ms.show ）
产品演示视频链接（如提供线上版本）	（待上传后填写）
测试账号 / 体验地址（如适用）	无需账号，公开可直接访问
模型权重仓库	https://modelscope.cn/models/DaiYanQBZ95Doll/SoundInsight_models

十二、附件命名规范

- zip命名：更新世界的锋芒_SoundInsight_复赛作品.zip
- 内含：
- 更新世界的锋芒_SoundInsight_复赛作品.pdf（主文档，由 `competition_v4.md` 导出）
 - 更新世界的锋芒_SoundInsight_Demo.zip
 - 更新世界的锋芒_SoundInsight_演示视频.mp4
 - 更新世界的锋芒_SoundInsight_其他材料.zip（验证报告、审计结果、图表、人工复核原始表）

十三、注意事项

- 所有材料打包为一个 zip 文件提交（天池渠道限制，zip 内可含子文件夹），zip 命名统一为「团队名_方案名称_复赛作品.zip」。
- zip 内按第十二部分命名规范整理文件，便于评委查阅。
- 演示视频建议控制在 3-5 分钟，展示核心业务流程即可；本项目视频脚本 `video_script.md` 当前为 130 秒版本，如需符合建议时长可扩充至 3 分钟以上。
- 作品不一定需要达到正式商业产品标准，但需证明方案可实现、可使用、具有业务价值；本项目的在线 Demo 与自动验收记录可用于此证明。

5. 代码仓库不强制公开源码，可私有仓库 + 授权评审可见，或用 Demo + 视频验证；本项目仓库为公开仓库。
6. 模型权重体积较大（约 536MB），未放入 zip，通过公开模型仓库自动下载，Demo 内 `download_models.py` 与部署包均已配置好下载链路。

脚注：本文档实验与交叉验证均基于 1257 条冻结口径；后续高音补捞扩展至 1288 条，中期置信区间复核后移除 8 条，当前工作集 1280 条；核心结论与冻结数字不受影响。